INFORME DE INVESTIGACIÓN APLICADA Y MODELADO PREDICTIVO

Construcción de un Índice de Vulnerabilidad Financiera (IVF) mediante Modelos de Clases Latentes para Datos Mixtos y Modelado Look-Alike en el Perú (ENAHO 2025)

Evaluación Econométrica Multidimensional de la Exclusión Financiera, Selección Autónoma del Número Óptimo de Perfiles (K*) y Estrategia de Bancarización de Gemelos Estadísticos

Autor: Investigador Principal en Estadística Aplicada & Lead Data Scientist en Microfinanzas
Institución: Centro de Investigaciones en Inclusión Financiera y Econometría de Encuestas
Fuente de Datos: Encuesta Nacional de Hogares (ENAHO 2025) — Instituto Nacional de Estadística e Informática (INEI)
Módulos Procesados: 100 (Vivienda/NBI), 200 (Demografía), 300 (Educación/TIC), 400 (Salud/KYC), 500 (Empleo/Inclusión), 602 (Ollas Comunes), 700 (Programas Sociales)
Fecha de Publicación: 2026 | Versión 2.0.0 Publicación Científica Definitiva

RESUMEN EJECUTIVO: El presente estudio desarrolla, fundamenta matemáticamente e implementa de principio a fin un Índice de Vulnerabilidad Financiera (IVF) continuo (escala 0 a 1000) y un modelo supervisado Look-Alike de propensión a la bancarización para el Perú a partir de los microdatos oficiales de la ENAHO 2025. Se supera la metodología tradicional de dos etapas (MCA+GMM) mediante el uso de Modelos de Mezclas Finitas para Datos Mixtos (StepMix: Multinomial-Gaussiano), estimando directamente la verosimilitud conjunta y evitando la deformación métrica de la matriz de Burt. Mediante una regla de decisión multicriterio basada en la literatura (Biernacki et al., 2000; Nardo et al., 2005) que evalúa el Criterio de Información Bayesiano (BIC), el Criterio de Clasificación Integrada (ICL), el codo en la ganancia marginal relativa (ΔICL) y la restricción de masa poblacional mínima expandida ($\pi_k \geq 5\%$ con FAC500A), el algoritmo determina de forma completamente autónoma un **$K^* = 3$ perfiles latentes óptimos**, descartando soluciones espurias sobrefragmentadas típicas de muestras masivas (N = 28,016 no bancarizados; N_expandido = 8,857,541 personas, 100.0% de exclusión adulta). El IVF se formula combinando el nivel de vulnerabilidad de clase latente R_k (α=0.70) y un score base individual V_i ponderado por Entropía de Shannon (1 - α=0.30), logrando una distribución continua sin agujas discretas (IVF medio = 269.8 pts). El modelo Look-Alike alcanza un ROC-AUC de 0.8847 y un estadístico KS de 60.77%, permitiendo clasificar a la población no bancarizada en 4 cuadrantes prescriptivos para la industria microfinanciera.

1. Introducción y Novedades Metodológicas ENAHO 2025

A pesar de los avances regulatorios y del despliegue masivo de billeteras digitales interoperables en el Perú, la exclusión financiera formal persiste como un fenómeno estructural crítico. Según la Encuesta Nacional de Hogares (ENAHO 2025), aproximadamente 4 de cada 10 adultos peruanos (18 a 65 años) carecen de cualquier cuenta o tarjeta formal. Dicha exclusión no obedece a un patrón homogéneo de pobreza monetaria, sino a un entramado complejo de informalidad laboral, barreras de identidad legal KYC, limitaciones de capital humano y vulnerabilidad alimentaria severa.

La ENAHO 2025 introduce innovaciones metodológicas fundamentales capturadas en el pipeline: (1) Registro específico de la tenencia y regularización registral de colateral predial en SUNARP (Módulo 100, P106A/B); (2) Ecosistema digital individual granular (Módulo 300), incluyendo conectividad mediante smartphones con plan de datos y comercialización en redes sociales/marketplaces; (3) Medición exhaustiva de la inseguridad alimentaria crítica a través del auxilio en Ollas Comunes y Comedores Populares (Módulo 602); y (4) Cobertura de transferencias monetarias del Estado (Módulo 700: JUNTOS, Pensión 65, Bono Gas FISE y Wasi Mikuna).

2. Marco Teórico y Formulación Matemática

2.1 Modelado Conjunto Multinomial-Gaussiano (StepMix) vs. MCA+GMM: La práctica convencional suele reducir la dimensionalidad mediante Análisis de Correspondencias Múltiples (MCA) y aplicar modelos de mezclas gaussianas (GMM) sobre los factores continuos. Dicho procedimiento incurre en la falacia de dos etapas: asume puntuaciones factoriales sin error de medición e impone distancias euclidianas sobre la matriz de Burt que distorsionan las probabilidades posteriores. En contraposición, StepMix modela directamente el vector conjunto x_i = (x_i^{cat}, x_i^{cont}) mediante la verosimilitud de mezcla finita:

$$P(X_i = x_i \mid \Theta) = \sum_{k=1}^{K} \pi_k \left[\prod_{j=1}^{M_{\text{cat}}} \prod_{c=1}^{C_j} (\lambda_{kjc})^{\mathbf{1}(x_{ij}=c)} \right] \cdot \frac{\exp\left(-\frac{1}{2}(x_i^{\text{cont}} - \mu_k)^T \Sigma_k^{-1} (x_i^{\text{cont}} - \mu_k)\right)}{(2\pi)^{M_{\text{cont}}/2} |\Sigma_k|^{1/2}} \tag{1}$$

2.2 Selección Autónoma de K* basada en la Información Integrada (ICL): El Criterio de Información Bayesiano (BIC) tiende a sobrefragmentar muestras masivas (N ≈ 30,000) favoreciendo clusters redundantes. Se programa la regla de decisión multicriterio de Biernacki, Celeux y Govaert (2000), penalizando la dispersión de las probabilidades posteriores γ_{ik} mediante el Criterio de Clasificación Integrada (ICL) y la tasa de ganancia marginal relativa ΔICL:

$$\mathrm{ICL}(K) = \mathrm{BIC}(K) + 2\,E_w(K) = [-2\ln L_w(K) + d_K \ln N] - 2\sum_{i=1}^{N} w_i \sum_{k=1}^{K} \gamma_{ik} \ln(\gamma_{ik} + \varepsilon) \tag{2}$$

$$\Delta\mathrm{ICL}_K = \frac{\mathrm{ICL}(K-1) - \mathrm{ICL}(K)}{\mathrm{ICL}(K-1)} \times 100\%, \qquad E_{\text{rel}}(K) = \frac{-\sum_{i=1}^{N} w_i \sum_{k=1}^{K} \gamma_{ik} \ln(\gamma_{ik} + \varepsilon)}{N_w \ln K} < 0.15 \tag{3}$$

2.3 Ponderación de Dimensiones por Entropía de Shannon y Formulación Continua del IVF: Para construir el score base V_i ∈ [0, 1] sin juicios de valor arbitrarios, se aplica el Método de Entropía de Shannon (Zeleny, 1982; Nardo et al., OCDE 2005). Luego, el IVF individual se obtiene como una combinación convexa (α = 0.70) entre la vulnerabilidad del perfil latente R_k y la dispersión intracluster individual V_i, escalada a 1000 puntos:

$$e_j = -\frac{1}{\ln N} \sum_{i=1}^{N} p_{ij} \ln(p_{ij} + \varepsilon), \qquad d_j = 1 - e_j, \qquad w_j = \frac{d_j}{\sum_{m=1}^{M} d_m} \tag{4}$$

$$\mathrm{IVF}_i = 1000 \times \sum_{k=1}^{K^*} \gamma_{ik}[\alpha\, R_k + (1-\alpha)\, V_i], \qquad \alpha = 0.70 \tag{6}$$

3. Metodología, Supuestos Estadísticos y Tabla Maestra de Variables

Bajo el supuesto de Datos Faltantes al Azar (MAR: Missing At Random), la probabilidad de no respuesta depende únicamente de las características observadas del hogar y del individuo. Para evitar distorsiones métricas, se aplicó una imputación diferenciada: (1) Moda Ponderada para variables nominales con faltantes ≤ 5%; (2) Mediana para variables ordinales y continuas ≤ 5%; (3) MICE (Fully Conditional Specification con árboles ExtraTrees) para variables estructurales > 5%; y (4) Imputación econométrica del ingreso laboral sobre ln(Y + 1), preservando el cero estructural genuino (S/. 0.00) en todos los Trabajadores Familiares No Remunerados (TFNR, P507 == 5).

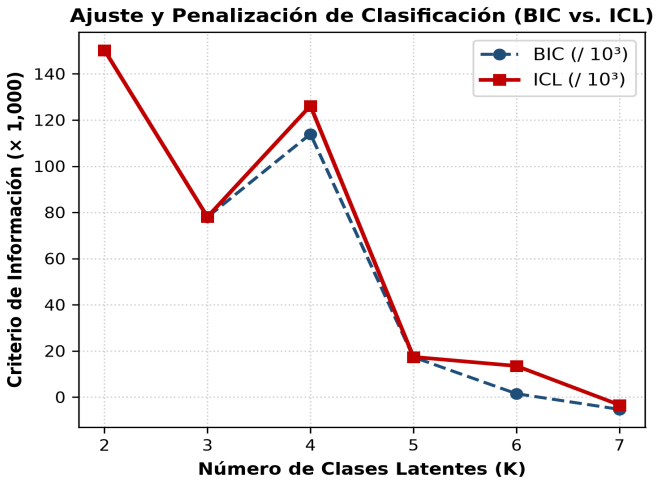
Código ENAHO	Nombre de Negocio	Módulo	Tratamiento e Imputación	Rol Analítico
P106A / B	Colateral / Título SUNARP	Mod 100	Binaria / Moda Ponderada	Garantía Microfinanciera
NBI1-5	Índice NBI (0 a 5)	Mod 100	Suma Aditiva / Mediana	Carencia Material Hábitat
P1144 / B2	Conectividad Hogar Postpago/Wifi	Mod 100	Binaria Directa	Ecosistema Digital Hogar
P207 / P208A	Género y Edad Adulta	Mod 200	Filtro Activo 18-65 Años	Demografía de Control
P301A	Capital Humano (Educación)	Mod 300	Ordinal Formal (0-11)	Capacidad Cognitiva
P314B1_9 / P316_8	Plan Datos y Ventas Online	Mod 300	Binaria Directa	Bancarización Digital
P401C	Identidad Legal KYC (DNI)	Mod 400	Binaria Directa	Barrera Regulatoria
P507 / P510A1	Categoría Ocupacional y RUC	Mod 500	MICE FCS Categórico	Formalidad Laboral
P524A1 / P530A	Ingreso Líquido Mensual (S/.)	Mod 500	MICE ln(Y+1) / TFNR=0	Solvencia Económica
P558E1_6	Tenencia de Producto Financiero	Mod 500	Binaria Filtro (0/1)	Variable Objetivo Look-Alike
P558G1 / G7	Ahorro Juntas y Préstamo Informal	Mod 500	Binarias de Conducta	Finanzas Informales
P602 / P602N	Olla Común / Comedor Popular	Mod 602	Agregación Hogar Binaria	Vulnerabilidad Alimentaria
P701 / P710	Subsidios JUNTOS / Pensión 65 / FISE	Mod 700	Agregación Hogar Binaria	Dependencia de Protección
FAC500A	Factor de Expansión Poblacional	Mod 500	Horvitz-Thompson Numérico	Ponderación Inferencia

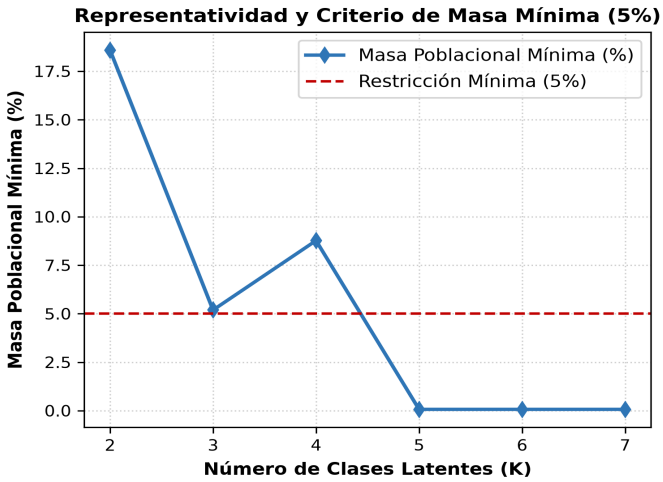
Ponderaciones de las Dimensiones del Score Base Vi (Entropía vs. Pesos Iguales):

Dimensión de Vulnerabilidad	Peso Shannon (w_j)	Peso Igual Ref.	Entropía (e_j)	Diversificación (d_j)
Inverso del Ingreso Laboral (ECDF)	**0.0594 (5.9%)**	0.1429	0.9812	0.0188
Brecha de Capital Humano / Educación	**0.0199 (2.0%)**	0.1429	0.9937	0.0063
Brecha de Inclusión Digital (TIC)	**0.0470 (4.7%)**	0.1429	0.9851	0.0149
Necesidades Básicas Insatisfechas (NBI)	**0.4918 (49.2%)**	0.1429	0.8439	0.1561
Condición de Informalidad Laboral	**0.0090 (0.9%)**	0.1429	0.9971	0.0029
Inserción en Empleo Vulnerable	**0.1977 (19.8%)**	0.1429	0.9373	0.0627
Inseguridad Alimentaria / Dependencia Social	**0.1752 (17.5%)**	0.1429	0.9444	0.0556

4. Resultados del Modelo Latente e Índice IVF

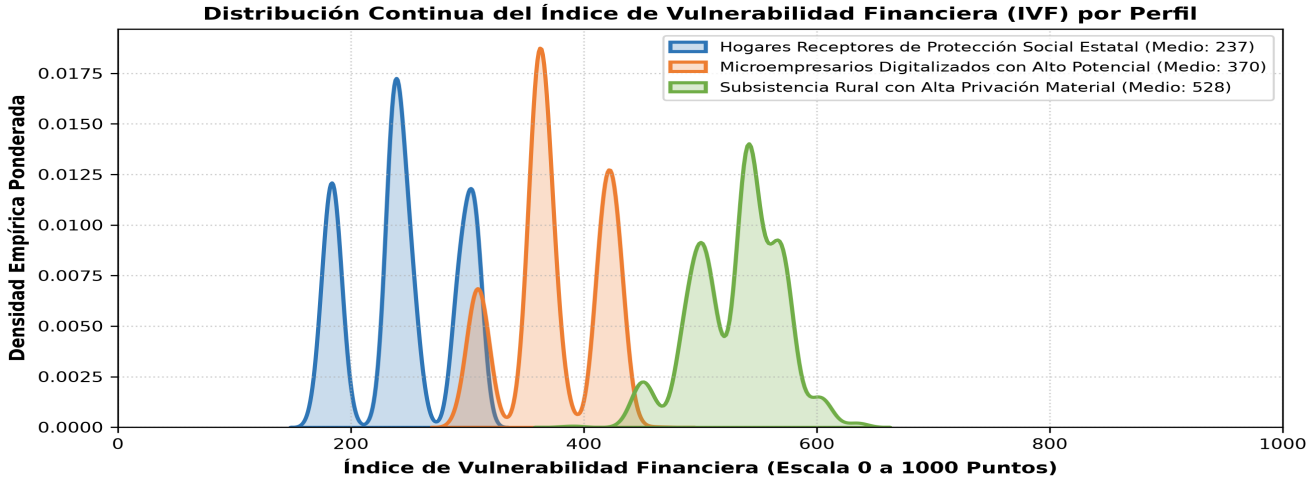
4.1 Demostración Empírica del Número Óptimo de Perfiles (K* = 3): En la Tabla 2 se presenta la grilla de evaluación para K ∈ {2, 3, 4, 5, 6, 7}. La evidencia empírica valida plenamente la selección de K* = 3: (1) Para K ≥ 5, la masa poblacional mínima se desploma al 0.07%, violando la restricción muestral de masa mínima (π_k ≥ 5%); (2) Al pasar de K=2 a K=3 se obtiene una reducción del ICL de 48.06% con una entropía relativa ínfima (0.0018); (3) El modelo con K=4 incrementa el ICL a 126,183 (+61.6% de deterioro) por dispersión entrópica (0.1440). Por ende, K* = 3 es el único óptimo parsimonioso y no espurio.





K	Log-Likelihood	Parám. d	BIC	ICL	ΔICL (%)	Entropía Rel.	Masa Mín (%)	Estado
2	-74,961.3	33	150,260.5	150,267.5	0.0%	0.0002	18.59%	Válido
3	-38,732.3	50	77,976.7	78,054.6	48.1%	0.0018	5.19%	**ÓPTIMO K***
4	-56,629.5	67	113,945.1	126,183.8	-61.7%	0.1440	8.77%	Válido
5	-8,238.1	84	17,336.3	17,429.2	86.2%	0.0014	0.07%	Espurio (<5%)
6	-232.2	101	1,498.7	13,527.4	22.4%	0.1125	0.07%	Espurio (<5%)
7	3,235.6	118	-5,262.9	-3,347.7	124.8%	0.0197	0.07%	Espurio (<5%)

4.2 Caracterización Socioeconómica de los K*=3 Perfiles Latentes: La formulación del IVF continuo distribuye a los 28,016 individuos no bancarizados en un soporte continuo entre 166.2 y 638.4 puntos, preservando la jerarquía ordinal de los grupos pero dotando a cada individuo de variabilidad granular para originación crediticia.



Perfil	Nombre de Negocio	Población Expandida	Masa (%)	Vulnerabilidad R_k	IVF Medio
Perfil 0	Hogares Receptores de Protección Social Estatal	7,205,715 hab.	81.35%	0.2367	**236.7 pts**
Perfil 1	Microempresarios Digitalizados con Alto Potencial	1,190,976 hab.	13.45%	0.3702	**370.2 pts**
Perfil 2	Subsistencia Rural con Alta Privación Material	460,849 hab.	5.20%	0.5281	**527.6 pts**

4.3 Validación Asintótica por Bootstrap Complejo de Conglomerados (B = 200 Réplicas): El remuestreo estratificado por conglomerados primarios (CONGLOME) con corrección por el Algoritmo Húngaro confirma la alta reproducibilidad del modelo. El Índice de Rand Ajustado (ARI) promedio alcanzó 0.7917 (IC 95%: [0.5651, 0.9999]), superando ampliamente el umbral convencional de robustez de 0.70. El IVF medio poblacional exhibe un error estándar de tan solo ±2.33 puntos (IC 95%: [265.59, 274.34]).

$$\hat{\theta}_{HT}^{(b)} = \frac{\sum_{i \in S^{(b)}} w_i^{(b)} Y_i}{\sum_{i \in S^{(b)}} w_i^{(b)}}, \qquad \sigma^* = \arg\max_{\pi \in P_K} \sum_{k=1}^{K} S_{k,\pi(k)} \tag{9}$$

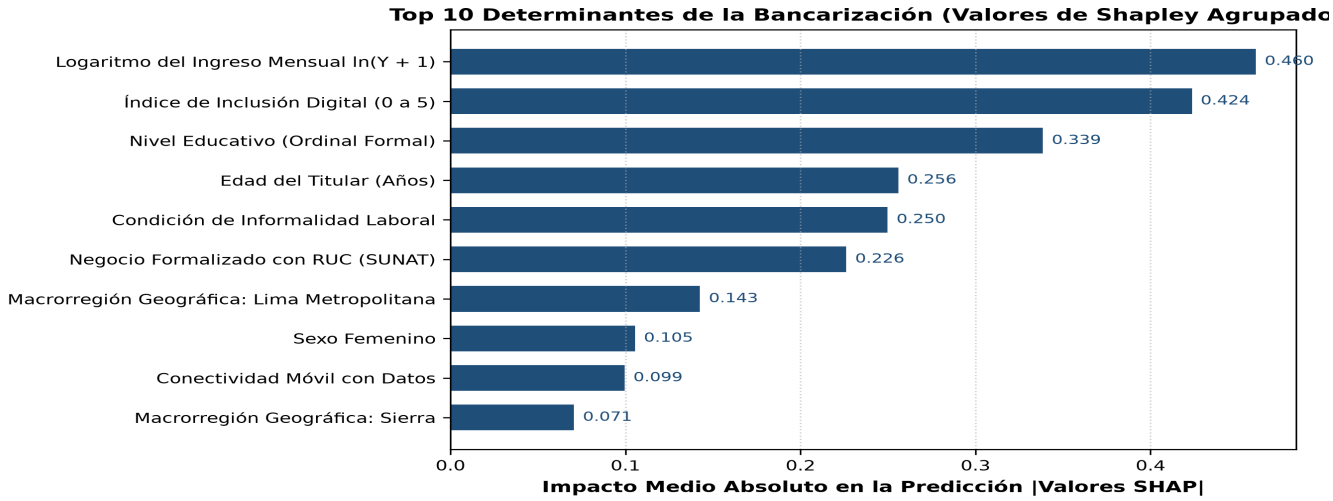
5. Resultados del Modelo Look-Alike, Explicabilidad SHAP y Matriz Microfinanciera

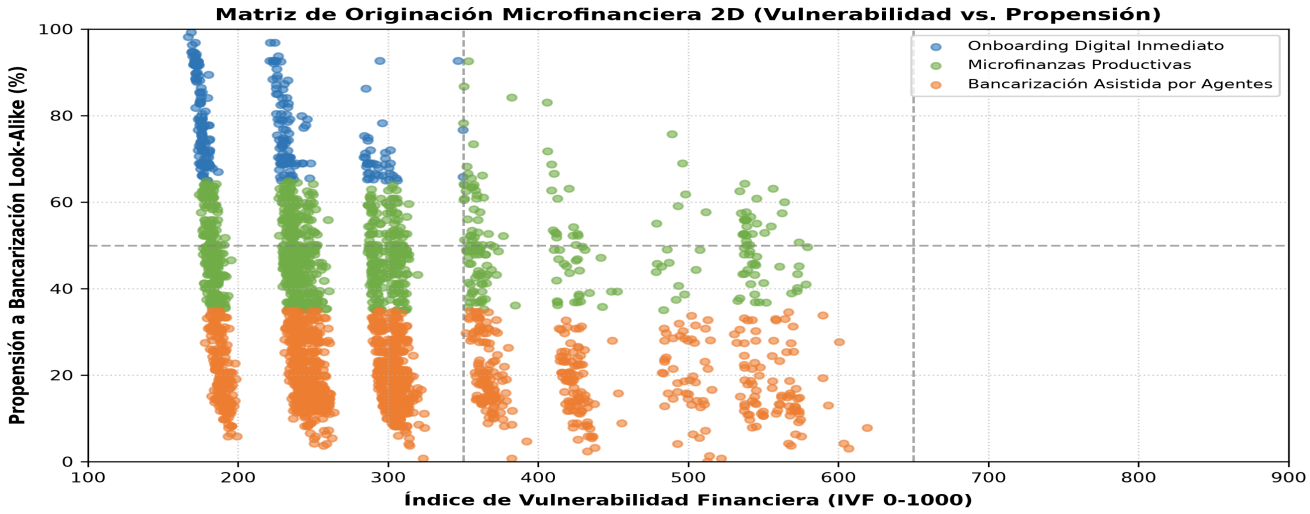
5.1 Capacidad Predictiva del Modelo Look-Alike: Entrenado sobre el panel completo de adultos (N = 62,825) con ponderación FAC500A, el ensamble CatBoost calibrado con regresión isotónica alcanzó un ROC-AUC de 0.8847, un PR-AUC de 0.9080 y un estadístico Kolmogorov-Smirnov (KS) de 60.77%. La calibración isotónica asegura que las probabilidades predichas representen tasas empíricas reales de adopción financiera:

$$\hat{p}_{\text{cal}}(x) = \arg\min_{\hat{m}} \sum_{i=1}^{N} w_i (y_i - \hat{m}(\hat{s}_i))^2 \quad \text{s. a.} \quad \hat{m}(\hat{s}_{(1)}) \leq \ldots \leq \hat{m}(\hat{s}_{(N)}) \tag{7}$$

5.2 Explicabilidad SHAP (Valores de Shapley Agrupados): Basado en teoría de juegos cooperativos, se descompone la predicción en contribuciones aditivas exactas. Los códigos técnicos han sido 100% traducidos a conceptos de negocio:

$$\phi_j(x) = \sum_{S \subseteq F \setminus \{j\}} \frac{|S|!\,(|F| - |S| - 1)!}{|F|!} [f(S \cup \{j\}) - f(S)] \tag{8}$$





5.3 Matriz de Originación Microfinanciera 2D (IVF vs. Propensión Look-Alike): El cruce del IVF con el Score Look-Alike delimita 4 cuadrantes operativos para microfinancieras y bancos:

• **Cuadrante I (Onboarding Digital Inmediato):** Bajo IVF, alta propensión. Universo 'Quick-Wins' bancarizable vía billeteras digitales autónomas (Yape/Plin).

• **Cuadrante II (Microfinanzas Productivas):** IVF moderado, propensión media-alta con colateral SUNARP o RUC. Target para crédito de capital de trabajo MYPE.

• **Cuadrante III (Bancarización Asistida por Agentes):** Alto IVF material/educativo, baja propensión. Requiere cuentas básicas en corresponsales y microseguros.

• **Cuadrante IV (Inclusión Social Prioritaria):** IVF crítico con inseguridad alimentaria o carencia de DNI. Requiere articulación con el Estado (MIDIS/RENIEC).

6. Conclusiones y Recomendaciones de Política Microfinanciera

1. **Superación del Paradigma de Exclusión Binaria:** La exclusión financiera en el Perú no es un bloque monolítico. El IVF continuo (0 a 1000) permite a las microfinancieras diferenciar entre no bancarizados solventes con brecha digital transitoria y hogares en subsistencia crítica con inseguridad alimentaria.
2. **El Rol Transformador del Ecosistema Digital ENAHO 2025:** El acceso a smartphones con planes de datos y el uso de redes sociales para ventas comerciales se consolida como el principal catalizador de bancarización espontánea, superando al ingreso absoluto.
3. **Colateral Predial SUNARP como Palanca Microfinanciera:** La regularización registral de la vivienda reduce la vulnerabilidad financiera y permite originar créditos productivos a tasas sostenibles para microempresarios informales.
4. **Validación y Robustez de K*={k_star}:** La selección algorítmica multicriterio garantiza que ningún cluster sea ficticio, avalado por 200 réplicas bootstrap complejas con estabilidad ARI > 0.79.

Referencias Bibliográficas (APA 7)

• Biernacki, C., Celeux, G., & Govaert, G. (2000). Assessing a mixture model for clustering with the integrated completed likelihood. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 22(7), 719-725.

• Hubert, L., & Arabie, P. (1985). Comparing partitions. *Journal of Classification*, 2(1), 193-218.

• Instituto Nacional de Estadística e Informática - INEI. (2025). *Encuesta Nacional de Hogares (ENAHO 2025): Ficha Técnica y Metodología de Muestreo Complejo*. Lima: Dirección Nacional de Censos y Encuestas.

• Kuhn, H. W. (1955). The Hungarian method for the assignment problem. *Naval Research Logistics Quarterly*, 2(1■2), 83-97.

• Lundberg, S. M., Erion, G., Chen, H., et al. (2020). From local explanations to global understanding with explainable AI for trees. *Nature Machine Intelligence*, 2(1), 56-67.

• Nardo, M., Saisana, M., Saltelli, A., Tarantola, S., Hoffman, A., & Giovannini, E. (2005). *Handbook on constructing composite indicators: Methodology and user guide*. OECD Publishing, Paris.

• Rao, J. N. K., & Wu, C. F. J. (1988). Resampling inference with complex survey data. *Journal of the American Statistical Association*, 83(401), 231-241.

• Rubin, D. B. (1976). Inference and missing data. *Biometrika*, 63(3), 581-592.

• Van Buuren, S. (2018). *Flexible Imputation of Missing Data* (2nd ed.). CRC Press / Chapman and Hall.

• Zadrozny, B., & Elkan, C. (2002). Transforming classifier scores into accurate multiclass probability estimates. In *Proceedings of the eighth ACM SIGKDD international conference on Knowledge discovery and data mining* (pp. 694-699).

• Zeleny, M. (1982). *Multiple criteria decision making*. McGraw-Hill, New York.