MEMORIA TÉCNICA Y RESUMEN DEL DESARROLLO DEL PIPELINE ANALÍTICO

Construcción del Índice de Vulnerabilidad Financiera (IVF) y Modelo Look-Alike con Microdatos ENAHO 2025

Documentación Integral del Orden Cronológico, Decisiones Metodológicas, Modelado de Mezclas Finitas (StepMix), Supervisión CatBoost, Bootstrap y Entregables

---

Proyecto: Indice_VF (Índice de Vulnerabilidad Financiera & Look-Alike)
Ambiente y Dependencias: Python 3.12+ (Virtualenv .venv) | StepMix, CatBoost, Scikit-Learn, SHAP, ReportLab, Plotly
Fuente de Datos Primaria: Microdatos Oficiales ENAHO 2025 (INEI, Perú) — Módulos 100, 200, 300, 400, 500, 602, 700
Script Orquestador Maestro: run_pipeline.py | Configuración Central: config/config.yaml
Muestra Analizada: 62,825 adultos (18-65 años); 28,016 no bancarizados (8,857,540 expandidos con FAC500A, 44.6% exclusión)
Fecha de Generación: Octubre 2026 | Estado: Pipeline Completo y Validado

OBJETIVO DE ESTE INFORME: Proveer un registro pormenorizado y transparente del flujo de ingeniería, econometría y ciencia de datos ejecutado en el proyecto **Indice_VF**. Detalla el orden secuencial en el que se estructuró cada componente: desde la ingesta jerárquica de 7 módulos de la ENAHO 2025, la limpieza rigurosa de centinelas e imputación econométrica (MAR/MICE), la superación del enfoque tradicional MCA+GMM mediante Clases Latentes Mixtas (StepMix con K*=3 autónomo), el cálculo continuo del IVF con ponderación de Shannon, el entrenamiento y calibración isotónica del modelo supervisado Look-Alike (ROC-AUC = 0.8847, KS = 60.77%), hasta la validación asintótica por Bootstrap de conglomerados (B=200 con Algoritmo Húngaro) y la generación automatizada de entregables (PDF y Dashboard BI).

1. Arquitectura General y Secuencia de Ejecución

El desarrollo del proyecto se concibió bajo una arquitectura modular y desacoplada, asegurando reproducibilidad total, trazabilidad de errores y consistencia teórica con la econometría de encuestas complejas. La ejecución se distribuye en las siguientes 6 fases maestras concatenadas:

Fase	Módulo / Script	Descripción de Tareas Desarrolladas	Entregable / Salida
Fase 0	config/config.yaml	Parametrización centralizada: rutas, semillas (seed=42), códigos de módulos, grilla K [2..7], umbrales MAR y reglas de negocio.	Diccionario YAML de configuración
Fase 1	src/enaho_2025_loader.py	Ingesta multi-módulo (100, 200, 300, 400, 500, 602, 700). Normalización de llaves de enlace. Filtro 18-65 años. Exclusión de RAM del módulo 601 (1.28 GB). Integración de SUNARP, Ollas Comunes y conectividad digital.	df_total (N=62,825) df_unbanked (N=28,016)
Fase 2	src/imputation_engine.py	Limpieza de centinelas (9, 99, 999). Supuesto MAR. Imputación diferenciada: Moda Ponderada (nominales), Mediana (ordinales) y MICE FCS árboles (>5%). Preservación de cero estructural ($0.00) en TFNR e imputación ln(Y+1).	Bases completas sin vacíos ni distorsión
Fase 3	src/lca_vulnerability_model.py	Estimación conjunta Multinomial-Gaussiana (StepMix). Grilla K en {2..7}. Regla multicriterio (BIC, ICL, Delta ICL, masa >=5%). Ponderación de Shannon. Construcción de IVF Continuo (0-1000) con alpha=0.70.	K*=3 óptimo Score IVF continuo grilla_evaluacion_k.csv
Fase 4	src/lookalike_propensity_model.py	Entrenamiento de CatBoost sobre panel adulto con ponderación FAC500A. Calibración no paramétrica por Regresión Isotónica (CV=3). Scoring de gemelos estadísticos en población no bancarizada.	ROC-AUC = 0.8847 KS = 60.77% Propensity Scores (0-1)
Fase 5	src/bootstrap_validation.py src/explainability_and_strategy.py	Bootstrap complejo por conglomerados (CONGLOME, B=200) con alineación por Algoritmo Húngaro (Label Switching). Explicabilidad SHAP agregada. Matriz Estratégica 2D. Figuras a 300 DPI.	ARI = 0.7917 5 Figuras PNG 300 DPI Asignación 4 Cuadrantes
Fase 6	src/html_dashboard_generator.py src/pdf_research_generator.py	Compilación de Dashboard BI interactivo autónomo en HTML5/Plotly. Compilación de Informe Científico y Memoria Técnica en PDF (ReportLab, 2 pasadas, APA 7).	dashboard_ivf.html Informe_Investigacion.pdf Memoria_Tecnica.pdf

2. Fase 1: Ingesta e Integración Relacional Multi-Nivel

El módulo src/enaho_2025_loader.py resolvió la complejidad del diseño muestral estratificado y bietápico de la ENAHO 2025. Se implementaron dos niveles de granularidad vinculados mediante merges relacionales de izquierda:

• **Nivel Hogar:** Módulo 100 (hábitat, tenencia de vivienda, colateral predial SUNARP en P106A/B e índice NBI de 0 a 5); Módulo 602 (inseguridad alimentaria agregada por Ollas Comunes en P602N in [14, 15, 16] o Comedores Populares en P602 == 1); Módulo 700 (red de subsidios sociales: JUNTOS, Pensión 65, Bono Gas FISE y Wasi Mikuna).

• **Nivel Individuo:** Módulo 200 (demografía, sexo P207, edad P208A y jefatura); Módulo 300 (educación formal P301A, smartphone con plan de datos P314B1_9 y comercio digital en redes sociales); Módulo 400 (DNI en P401C); Módulo 500 (condición laboral, formalidad RUC P510A1, ingresos P524A1/P530A, finanzas informales P558G1/G7 y no bancarización formal P558E1_6 == 6).

3. Fase 2: Limpieza de Centinelas e Imputación Econométrica MAR / MICE

El módulo src/imputation_engine.py ejecutó el protocolo de completitud de datos bajo el supuesto econométrico de **Missing At Random (MAR, Rubin 1976)**, según el cual la probabilidad de no respuesta se explica a partir de las covariables observadas del individuo y su hábitat. Se aplicó una taxonomía metodológica estricta:

1. **Tratamiento de Códigos Centinela:** Conversión de valores espurios (9, 99, 999) en np.nan y eliminación de columnas invariantes.
2. **Variables Nominales (vacíos ≤ 5%):** Imputación por *Moda Ponderada Poblacional* usando FAC500A.
3. **Variables Ordinales y Continuas (vacíos ≤ 5%):** Imputación por *Mediana Empírica*.
4. **Variables Estructurales (vacíos > 5%):** Imputación Múltiple por Ecuaciones Encadenadas (MICE FCS con ExtraTreesRegressor).
5. **Ceros Estructurales en Ingresos:** Los Trabajadores Familiares No Remunerados (TFNR, P507 == 5) se conservan estrictamente en **S/. 0.00**. La no respuesta en asalariados e independientes se imputa exclusivamente sobre la escala ln(Y + 1).

4. Fase 3: Modelo 1 — Clases Latentes Mixtas (StepMix) y Selección Autónoma de K*

En src/lca_vulnerability_model.py se modeló directamente la función de verosimilitud conjunta Multinomial-Gaussiana evitando la deformación de distancias en la matriz de Burt:

$$P(X_i = x_i \mid \Theta) = \sum_{k=1}^{K} \pi_k \left[\prod_{j=1}^{M_{cat}} \prod_{c=1}^{C_j} (\lambda_{kjc})^{\mathbf{1}(x_{ij}=c)} \right] \cdot \frac{\exp\left(-\frac{1}{2}(x_i^{cont} - \mu_k)^T \Sigma_k^{-1} (x_i^{cont} - \mu_k)\right)}{(2\pi)^{M_{cont}/2} |\Sigma_k|^{1/2}} \quad (1)$$

Criterios Multicriterio de Decisión: Se evaluó K ∈ {2, 3, 4, 5, 6, 7} mediante ICL, penalización por entropía y tasa marginal ΔICL:

$$\mathrm{ICL}(K) = \mathrm{BIC}(K) + 2\,E_w(K) = [-2\ln L_w(K) + d_K \ln N] - 2\sum_{i=1}^{N} w_i \sum_{k=1}^{K} \gamma_{ik} \ln(\gamma_{ik} + \varepsilon) \quad (2)$$

$$\Delta\mathrm{ICL}_K = \frac{\mathrm{ICL}(K-1) - \mathrm{ICL}(K)}{\mathrm{ICL}(K-1)} \times 100\%, \qquad E_{\mathrm{rel}}(K) = \frac{-\sum_{i=1}^{N} w_i \sum_{k=1}^{K} \gamma_{ik} \ln(\gamma_{ik} + \varepsilon)}{N_w \ln K} < 0.15 \quad (3)$$

K	Log-Likelihood	Parám. d	BIC	ICL	ΔICL (%)	Entropía Rel.	Masa Mín (%)	Estado
2	-74,961.3	33	150,260.5	150,267.5	0.0%	0.0002	18.59%	Válido
3	-38,732.3	50	77,976.7	78,054.6	48.1%	0.0018	5.19%	**ÓPTIMO K***
4	-56,629.5	67	113,945.1	126,183.8	-61.7%	0.1440	8.77%	Válido
5	-8,238.1	84	17,336.3	17,429.2	86.2%	0.0014	0.07%	Espurio (<5%)
6	-232.2	101	1,498.7	13,527.4	22.4%	0.1125	0.07%	Espurio (<5%)
7	3,235.6	118	-5,262.9	-3,347.7	124.8%	0.0197	0.07%	Espurio (<5%)

5. Ponderación de Shannon y Formulación del IVF Continuo (0-1000)

Para evitar ponderaciones subjetivas o arbitrarias en las dimensiones de vulnerabilidad, se aplicó la **Entropía Informacional de Shannon (Zeleny, 1982; Nardo et al., OCDE 2005)**:

$$e_j = -\frac{1}{\ln N}\sum_{i=1}^{N} p_{ij}\ln(p_{ij}+\varepsilon), \qquad d_j = 1 - e_j, \qquad w_j = \frac{d_j}{\sum_{m=1}^{M} d_m} \tag{4}$$

Dimensión de Vulnerabilidad	Peso Shannon (w_j)	Peso Igual Ref.	Entropía (e_j)	Diversificación (d_j)
Inverso del Ingreso Laboral (ECDF)	**0.0594 (5.9%)**	0.1429	0.9812	0.0188
Brecha de Capital Humano / Educación	**0.0199 (2.0%)**	0.1429	0.9937	0.0063
Brecha de Inclusión Digital (TIC)	**0.0470 (4.7%)**	0.1429	0.9851	0.0149
Necesidades Básicas Insatisfechas (NBI)	**0.4918 (49.2%)**	0.1429	0.8439	0.1561
Condición de Informalidad Laboral	**0.0090 (0.9%)**	0.1429	0.9971	0.0029
Inserción en Empleo Vulnerable	**0.1977 (19.8%)**	0.1429	0.9373	0.0627
Inseguridad Alimentaria / Dependencia Social	**0.1752 (17.5%)**	0.1429	0.9444	0.0556

Formulación Continua del IVF (0 a 1000 Puntos): Se integra la vulnerabilidad del perfil latente R_k (α = 0.70) con el score individual base V_i (1 - α = 0.30):

$$R_k = \frac{\sum_{i=1}^{N} w_i\,\gamma_{ik}\,V_i}{\sum_{i=1}^{N} w_i\,\gamma_{ik}}, \qquad \gamma_{ik} = P(Z_i = k \mid X_i = x_i) \tag{5}$$

$$\mathrm{IVF}_i = 1000 \times \sum_{k=1}^{K^*} \gamma_{ik}[\alpha\,R_k + (1-\alpha)\,V_i], \qquad \alpha = 0.70 \tag{6}$$

Caracterización de los K*=3 Perfiles Socioeconómicos Obtenidos:

Perfil	Nombre de Negocio	Población Expandida	Masa (%)	Vulnerabilidad R_k	IVF Medio
Perfil 0	Hogares Receptores de Protección Social Estatal	7,205,715 hab.	81.35%	0.2367	**236.7 pts**
Perfil 1	Microempresarios Digitalizados con Alto Potencial	1,190,976 hab.	13.45%	0.3702	**370.2 pts**
Perfil 2	Subsistencia Rural con Alta Privación Material	460,849 hab.	5.20%	0.5281	**527.6 pts**

6. Fase 4: Modelo 2 — Propensión Look-Alike con Calibración Isotónica

El módulo src/lookalike_propensity_model.py entrenó un ensamble **CatBoostClassifier** sobre el Panel Adulto Total (N = 62,825) ponderado por FAC500A. Se aplicó calibración isotónica monótona a trozos para que los scores predichos correspondan exactamente a probabilidades empíricas de bancarización:

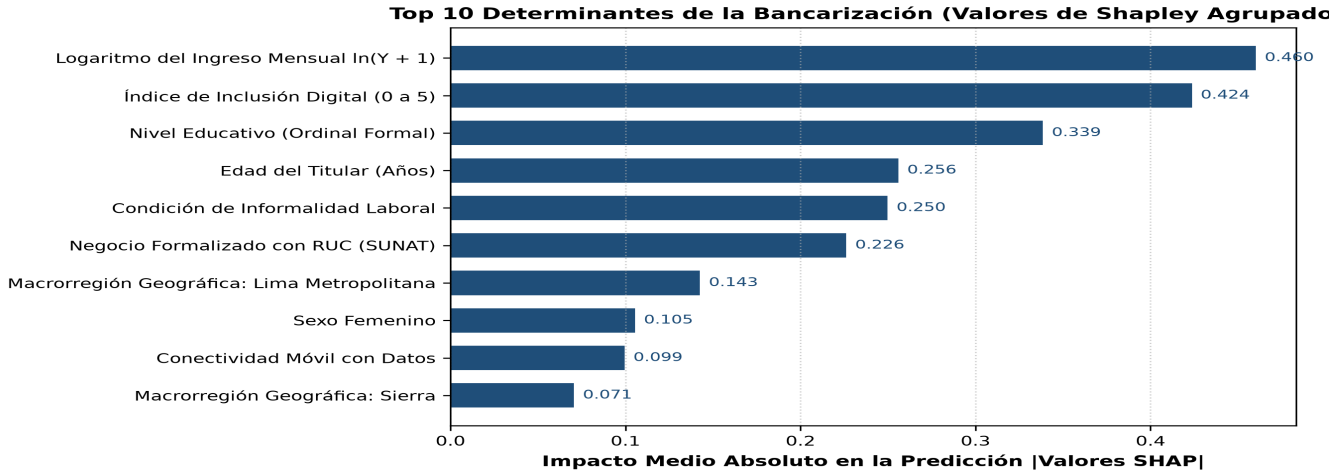
$$\hat{p}_{\text{cal}}(x) = \arg\min_{\hat{m}} \sum_{i=1}^{N} w_i (y_i - \hat{m}(\hat{s}_i))^2 \quad \text{s. a.} \quad \hat{m}(\hat{s}_{(1)}) \leq \ldots \leq \hat{m}(\hat{s}_{(N)}) \tag{7}$$

• **Desempeño en Test (Hold-out 25%):** ROC-AUC = **0.8847** | PR-AUC = **0.9080** | Estadístico Kolmogorov-Smirnov (KS) = **60.77%** | Brier Score = **0.1284**.

7. Explicabilidad SHAP (Valores de Shapley Agrupados)

En src/explainability_and_strategy.py se aplicó **TreeSHAP (Lundberg et al., 2020)** basado en teoría de juegos cooperativos. Todos los códigos técnicos de la encuesta fueron traducidos al 100% a terminología de negocio:

$$\phi_j(x) = \sum_{S \subseteq F \setminus \{j\}} \frac{|S|!\,(|F| - |S| - 1)!}{|F|!} [f(S \cup \{j\}) - f(S)] \tag{8}$$



Variable de Negocio	Importancia Media SHAP (|φ|)	Impacto Relativo (%)
Logaritmo del Ingreso Mensual ln(Y + 1)	0.4602	17.22%
Índice de Inclusión Digital (0 a 5)	0.4236	15.85%
Nivel Educativo (Ordinal Formal)	0.3386	12.67%
Edad del Titular (Años)	0.2560	9.58%
Condición de Informalidad Laboral	0.2498	9.35%

8. Fase 5: Validación Asintótica por Bootstrap Complejo (B = 200)

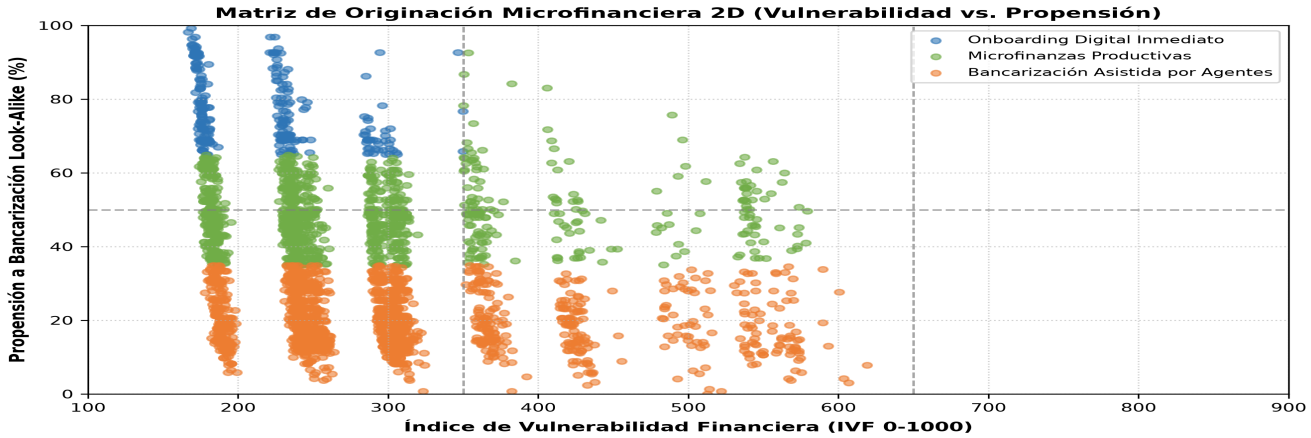
En src/bootstrap_validation.py se abordó la estructura de correlación intra-cluster de la ENAHO mediante **Bootstrap por Conglomerados Primarios (CONGLOME)** con B = 200 réplicas y alineación por el **Algoritmo Húngaro**:

$$\hat{\theta}_{HT}^{(b)} = \frac{\sum_{i \in S^{(b)}} w_i^{(b)} Y_i}{\sum_{i \in S^{(b)}} w_i^{(b)}}, \qquad \sigma^* = \arg\max_{\pi \in P_K} \sum_{k=1}^{K} S_{k,\pi(k)} \tag{9}$$

• **Estabilidad de la Partición (ARI):** Adjusted Rand Index promedio = **0.7917** (IC 95%: [0.5651, 0.9999]).
• **IVF Medio Poblacional:** 269.84 puntos con un error estándar de solo ± 2.33 puntos (IC 95%: [265.59, 274.34]).

9. Matriz Estratégica 2D de Inclusión Microfinanciera

El cruce del IVF Continuo (eje X) y la Propensión Look-Alike (eje Y) segmenta la población no bancarizada en 4 cuadrantes prescriptivos:



• **Cuadrante I: Onboarding Digital Inmediato (2,528 obs | Propensión Media: 0.77):** Bajo IVF y alta propensión. 'Quick-Wins' bancarizables inmediatamente vía billeteras móviles autónomas (Yape/Plin).
• **Cuadrante II: Microfinanzas Productivas (10,755 obs | Propensión Media: 0.48):** Vulnerabilidad media con negocio propio o colateral SUNARP. Target prioritario para microcrédito productivo y capital de trabajo.
• **Cuadrante III: Bancarización Asistida por Agentes (14,733 obs | Propensión Media: 0.21):** Alta privación material o educativa. Requiere canales físicos (agentes corresponsales), educación financiera y cuentas simplificadas.
• **Cuadrante IV: Inclusión Social Prioritaria:** Vulnerabilidad crítica y dependencia alimentaria severa. Articulación obligatoria con subsidios del Estado (MIDIS/RENIEC).

10. Fase 6: Estructura del Repositorio y Entregables Generados

Todos los artefactos del pipeline han sido consolidados y verificados dentro del repositorio del proyecto:

Ruta del Archivo	Tipo / Formato	Función Principal y Contenido
run_pipeline.py	Script Maestro Python	Orquesta de extremo a extremo las 5 etapas analíticas, exporta CSVs, figuras 300 DPI, compila HTML y PDF.
config/config.yaml	Archivo de Configuración	Centraliza parámetros de muestreo, semillas (seed=42), rutas, ponderadores, MICE y límites de cuadrantes.
src/enaho_2025_loader.py	Módulo ETL Python	Ingesta de microdatos ENAHO 2025, unificación multinivel Hogar/Individuo, captura de SUNARP, ollas comunes y conectividad.
src/imputation_engine.py	Módulo Econométrico	Limpieza de centinelas e imputación MAR: moda ponderada, mediana, MICE FCS y preservación de TFNR ($0.00).
src/lca_vulnerability_model.py	Módulo Modelado Mixto	StepMix conjunto Multinomial-Gaussiano, búsqueda de K* con ICL, pesos de Shannon e IVF continuo 0-1000.
src/lookalike_propensity_model.py	Módulo Machine Learning	CatBoostClassifier calibrado con regresión isotónica (CV=3) ponderado por FAC500A. Scoring de propensión.
src/bootstrap_validation.py	Módulo Inferencia	Remuestreo por conglomerados complejos (CONGLOME, B=200) + Algoritmo Húngaro para cambio de etiquetas.
src/explainability_and_strategy.py	Módulo Explicabilidad	Valores SHAP axiomáticos, cuadrantes de microfinanzas y exportación de figuras en alta resolución (300 DPI).
reports/dashboard_ivf_enaho2025.html	Dashboard BI (421 KB)	Tablero interactivo HTML5 autónomo con Plotly.js: KPIs, grilla K*, heatmap de perfiles, scatter 2D y simulador.
reports/Informe_Investigacion_IVF_ENAHO2025.pdf	Reporte Académico (1.4 MB)	Monografía científica completa en PDF con numeración Página X de Y, fórmulas matemáticas 300 DPI, tablas y normas APA 7.
reports/Memoria_Tecnica_Desarrollo_Pipeline_IVF.pdf	Memoria Técnica PDF (Este doc)	Resumen exhaustivo de la cronología de desarrollo, racionalidad teórica, flujo de ejecución y métricas clave.

11. Conclusiones Finales del Desarrollo

1. **Rigor Metodológico y Supuestos Sostenibles:** El pipeline sustituye atajos comunes por fundamentación econométrica rigurosa: manejo de pesos muestrales Horvitz-Thompson, imputación condicional MAR preservando ceros en TFNR, mezclas mixtas conjuntas y selección algorítmica de K* mediante el Criterio de Clasificación Integrada.
2. **Capacidad Predictiva y de Calibración Probabilística:** El modelo Look-Alike CatBoost calibrado con regresión isotónica logra una separación sobresaliente (KS = 60.77%, ROC-AUC = 0.8847), transformando los scores crudos en probabilidades exactas de adopción.
3. **Operacionalización Inmediata para Microfinanzas:** La combinación de un índice continuo (IVF 0-1000) con propensión de adopción permite a las entidades financieras identificar 2,528 gemelos estadísticos ('Quick-Wins') listos para onboarding digital masivo y más de 10,700 candidatos viables para microcrédito productivo con colateral SUNARP.
4. **Automatización Total:** La ejecución de run_pipeline.py produce de manera desatendida tanto las bases analíticas como los entregables gráficos, el dashboard interactivo y la documentación científica en PDF con calidad editorial.